📑 Résumé Technique de l'Implémentation

1. Architecture Globale

L'application est une **Single Page Application (SPA)** développée avec le framework **Streamlit**. Elle suit une architecture modulaire séparant la logique d'interface (Frontend) de la logique de traitement de données et de modélisation (Backend ML).

2. Pipeline de Machine Learning (Scikit-learn)

Le cœur du système repose sur un objet Pipeline de Scikit-learn, garantissant que toutes les étapes de transformation des données sont encapsulées avec le modèle. Cela évite les fuites de données (data leakage) et simplifie le déploiement.

- **Pré-traitement (Preprocessing) :**
  - Utilisation d'un ColumnTransformer pour appliquer des traitements différenciés.
  - **Données Catégorielles** (country, city, property_type) : Traitées via OneHotEncoder (gestion des nouvelles catégories via handle_unknown='ignore').
  - **Données Numériques** : Passées telles quelles (passthrough), le modèle choisi étant peu sensible à l'échelle des données.
- **Modélisation :**
  - Algorithme : **RandomForestRegressor**.
  - Justification : Modèle d'ensemble robuste, capable de capturer des relations non-linéaires complexes sans nécessiter de normalisation stricte.
- **Optimisation (Tuning) :**
  - Méthode : GridSearchCV.
  - Stratégie : Recherche exhaustive sur une grille d'hyperparamètres définie dynamiquement par l'utilisateur (n_estimators, max_depth, min_samples_leaf).
  - Validation : Cross-validation à 3 plis (cv=3) optimisant la métrique *Negative Mean Absolute Error*.

3. Gestion des Données et Sérialisation

- **Nettoyage (ETL) :** Conversion robuste des types (casting explicite en str pour éviter les erreurs de tri), gestion des valeurs manquantes (dropna), et ingénierie de fonctionnalités (création de property_age).
- **Sérialisation :** Utilisation de joblib pour sauvegarder non seulement le modèle, mais un **dictionnaire d'état complet** contenant : le pipeline entraîné, les métriques de performance (R^2, MAE), les noms des features, et le dataset original (pour les comparaisons de marché).

4. Visualisation (Plotly)

L'interface intègre des graphiques interactifs via **Plotly Express** et **Graph Objects**, offrant une analyse visuelle de la position du bien par rapport au marché (histogrammes, diagrammes en radar pour le profil du bien, et barres d'intervalles de confiance).

📚 Glossaire Technique & Définitions

Voici les définitions précises des termes techniques utilisés dans votre code :

Terme	Définition & Usage dans votre code
Pipeline	Objet Scikit-learn qui enchaîne séquentiellement des étapes de transformation (ex: encodage) et un estimateur final (modèle). Il assure que les mêmes transformations sont appliquées aux données d'entraînement et aux nouvelles données à prédire.
RandomForest	"Forêt Aléatoire". C'est un méta-estimateur qui entraîne plusieurs arbres de décision sur divers sous-ensembles de données et fait la moyenne de leurs résultats pour améliorer la précision et contrôler le sur-apprentissage (overfitting).
OneHotEncoder	Technique transformant des variables catégorielles (texte) en vecteurs binaires (0 ou 1). Exemple : "Paris" devient [1, 0, 0], "Lyon" devient [0, 1, 0]. Essentiel car les modèles mathématiques ne comprennent que les chiffres.
GridSearchCV	"Recherche sur Grille avec Validation Croisée". Algorithme qui teste méthodiquement toutes les combinaisons possibles d'hyperparamètres fournis (ex: profondeur de l'arbre) pour trouver la configuration offrant la meilleure performance moyenne.
Hyperparamètres	Paramètres de configuration du modèle qui ne sont pas appris via les données mais fixés avant l'entraînement (ex: max_depth, n_estimators). Votre interface permet de les ajuster dynamiquement.

R^2 (R-squared)	Coefficient de détermination. Il mesure la proportion de la variance de la variable cible (prix) qui est prévisible à partir des variables explicatives. Un R^2 de 1.0 signifie une prédiction parfaite.
MAE	*Mean Absolute Error*. C'est la moyenne arithmétique des erreurs absolues. Si le MAE est de 20 000€, le modèle se trompe en moyenne de ce montant (en plus ou en moins).
Session State	Mécanisme de Streamlit (st.session_state) permettant de persister des variables (comme le modèle chargé ou le résultat d'une estimation) entre les rechargements de page interactifs.

🚀 Guide de Démarrage Rapide

Voici comment lancer votre application sur votre machine locale.

1. Pré-requis

Assurez-vous d'avoir **Python 3.8+** installé.

2. Installation des dépendances

Ouvrez votre terminal et installez les bibliothèques nécessaires :

pip install streamlit pandas numpy scikit-learn joblib plotly

3. Préparation des fichiers

Créez un dossier projet et placez-y les fichiers suivants :

1. **app.py** : Copiez-collez l'intégralité du code v6 fourni ci-dessus.
2. **global_house_purchase_dataset.csv** : Votre fichier de données (nécessaire pour l'entraînement).
3. *(Optionnel)* **mon_modele_immobilier_v1.joblib** : Si vous avez déjà un modèle entraîné.

4. Lancement de l'application

Dans votre terminal, naviguez vers le dossier du projet (cd chemin/vers/dossier) et exécutez :

streamlit run app.py

5. Utilisation

Une page web s'ouvrira automatiquement (généralement sur http://localhost:8501).

- **Si vous n'avez pas de modèle :** Allez dans l'onglet **"🚀 Entraînement"**, chargez votre CSV, configurez les hyperparamètres, lancez l'entraînement, puis téléchargez le fichier .joblib généré.
- **Si vous avez un modèle :** Placez le fichier .joblib à côté de app.py (ou renommez-le selon la variable NOM_FICHIER_MODELE dans le code) et rafraîchissez la page pour utiliser l'onglet **"🏠 Estimation"**.